Parseur / Validateur XML-Lite

Mathis Deloge, Antoine Petot, Ange Picard

Lundi 10 octobre 2016

- 1 Présentation du sujet
 - Le sujet
 - Prolongements possibles
 - Le XML-Lite
 - La structure du document
- 2 Modèle mathématique
- 3 Résultats
- 4 Présentation du programme
- 5 Conclusion

Le sujet

Le XML-Lite

Le XML est un langage de balisage générique très utilisé en informatique. Nous utiliserons une version simplifiée : le XML-Lite.

Descriptif

Comme cité dans le sujet, un parseur / validateur XML-Lite est un programme capable de lire un fichier, d'indiquer s'il vérifie la norme XML-Lite et si oui, de l'analyser et de retenir sa structure ainsi que son contenu.

Le programme devra également être capable de vérifier si la structure d'un document donné vérifie une structure présente dans un Document appelé DTD.

Prolongements possibles

Les différents prolongements du sujet

- Permettre le débuggage du fichier XML.
- Permettre au validateur de s'accorder à un schéma prédéfini.
- Modifier le validateur afin qu'il prenne en compte un schéma.
- Ajouter un interpréteur suivant le schéma d'un générateur de QCM.

Le XML-Lite

Les règles

- Une balise possède un nom.
- Une balise doit être ouverte puis fermée.
- Une balise peut contenir du texte.
- Une balise peut contenir d'autre balises.
- L'ordre des balises filles n'a pas d'importance et tout le texte contenu dans une balise est regroupé en un seul bloc.
- Une balise fille doit être fermée avant la fermeture de la balise parent.
- Une balise peut contenir une balise du même nom.
- Un document doit commencer par l'ouverture d'une balise se fermant à la fin du document.

Exemples de XML-Lite

XML-Lite correct

Raisons

- Une balise s'ouvre en début de document et se ferme en fin.
- Respect de toutes les règles d'ouverture et fermeture de balise.
- Toutes les balises sont correctement imbriquées et nommées.

Exemples de XML-Lite

XML-Lite faux

Raisons

- Les balises ne sont pas correctement imbriquées.
- Une balise n'est pas correctement nommée.
- Une balise s'ouvre et ne se referme pas.

La structure du document

Descriptif

Le parseur / validateur doit être capable de lire n'importe quel fichier XML-Lite mais doit aussi être en mesure d'attendre une certaine structure de document grâce à l'ajout d'un fichier .dtd appelé schéma. Grâce aux fichiers schéma, le parseur / validateur connais avec plus de finesse les balises filles autorisées ou non pour chaque balises. C'est une sorte de modèle qui permettra la validation du fichier XML-Lite.

- 1 Présentation du sujet
- 2 Modèle mathématique
 - Choix du modèle mathématique
 - Représentation de l'automate fini
- 3 Résultats
- 4 Présentation du programme
- 5 Conclusion

Choix du modèle mathématique

Un automate fini

Pour nous permettre de parcourir rapidement un fichier XML-Lite, nous avons opté pour le développement d'un automate fini.

Choix du modèle mathématique

Un automate fini

Pour nous permettre de parcourir rapidement un fichier XML-Lite, nous avons opté pour le développement d'un automate fini.

Simplicité et rigidité

Très peu d'états différents lors de la lecture d'un fichier XML-Lite. Les transitions entre états se font uniquement grâce à la différenciation des caractères '<', '>', '/' avec le reste.

Choix du modèle mathématique

Un automate fini

Pour nous permettre de parcourir rapidement un fichier XML-Lite, nous avons opté pour le développement d'un automate fini.

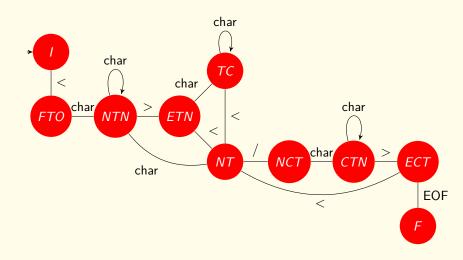
Simplicité et rigidité

Très peu d'états différents lors de la lecture d'un fichier XML-Lite. Les transitions entre états se font uniquement grâce à la différenciation des caractères '<', '>', '/' avec le reste.

Efficacité

Cette façon de parcourir un fichier XML-Lite caractère par caractère s'est avérée très rapide (exécution en 13ms pour un fichier XML-Lite de près de 700Mo).

Représentation de l'automate fini



Légende de l'automate

Légende

```
Initial
```

FTO First Tag Opening

NTN New Tag Name

ETN End Tag Name

TC Text Content

NT New Tag

NCT New Closing Tag

CTN Colsing Tag Name

ECT End Closing Tag

F Final

- 1 Présentation du sujet
- 2 Modèle mathématique
- 3 Résultats
- 4 Présentation du programme
- 5 Conclusion

Résultats

- 1 Présentation du sujet
- 2 Modèle mathématique
- 3 Résultats
- 4 Présentation du programme
 - Le parseur
 - Le validateur
 - L'interpréteur
- 5 Conclusion

Le parseur

Parseur

Le validateur

Validateur

```
import java.util.regex.Pattern;
3
   /**
    * Created by MrMan on 12/09/2016.
5
   */
   public class main {
       public static void main(String[] args)
8
           //TODO remove all todos before the
                end
9
           //TODO if we have time : verify
               class structure
10
           long startTime = System.
               currentTimeMillis();
```

L'interpréteur

Interpréteur

```
TransitionSystem ts = new
               TransitionSystem();
           Node rootNode = null;
           try {
                ts.parseFile("XMLDocs\\Ok.xmll
                   ");
                rootNode = Parser.getInstance
                   ().getRootNode();
                SchemaInterpreter
                   schemaInterpreter =
                   SchemaInterpreter.
                   getInstance();
10
                schemaInterpreter.validateTree
```

- 1 Présentation du sujet
- 2 Modèle mathématique
- 3 Résultats
- 4 Présentation du programme
- 5 Conclusion

Conclusion

Difficultés rencontrées

yolo

Outils acquis

yolo

- 1 Présentation du sujet
 - Le sujet
 - Prolongements possibles
 - Le XML-Lite
 - XML-Lite correct
 - XML-Lite faux
 - La structure du document
- 2 Modèle mathématique
 - Choix du modèle mathématique
 - Représentation de l'automate fini
- 3 Résultats
- 4 Présentation du programme
 - Le parseur
 - Le validateur
 - L'interpréteur
- 5 Conclusion