

Rapport du projet XMLLiteParser

Modélisation

Mathis Deloge, Antoine Petot, Ange Picard

1 Descriptif du sujet

Comme cité dans le sujet, un parseur / validateur XML-Lite est un programme capable de lire un fichier, d'indiquer s'il vérifie la norme XML-Lite et si oui, de l'analyser et de retenir sa structure ainsi que son contenu. Pour nous permettre de concevoir un programme réalisable, notre parseur / validateur opère sur un langage simplifié de XML, le XML-Lite conçu pour faciliter l'utilisation, les performances ainsi que les normes de conformité (XML 1.0).

1.1 Le XML-Lite

Pour être considéré comme du XML-Lite, les fichiers parsés / validés par notre programme doivent respecter certaines règles :

- Une balise possède un nom.
- Une balise doit être ouverte puis fermée.
- Une balise peut contenir du texte.
- Une balise peut contenir d'autres balises.
- L'ordre des balises filles n'a pas d'importance et tout le texte contenu dans une balise est regroupé en un seul bloc.
- Une balise fille doit être fermée avant la fermeture de la balise parent.
- Une balise peut contenir une balise du même nom.
- Un document doit commencer par l'ouverture d'une balise se fermant à la fin du document.

1.2 Exemple de fichiers XML-Lite

1.2.1 Fichier XML-Lite correct

```
1 | <FirstTag>
2 |     <ChildTag>
3 |         <AnotherChildTag>
4 |         </AnotherChildTag>
5 |     </ChildTag>
6 |     <tag>
7 |     </tag>
8 | </FirstTag>
```

1.2.2 Fichier XML-Lite Faux

```
1 | <FirstTag>
2 |     <SecondTag>
3 |         <EndTag>
4 |         <AloneTag>
5 |     </>
6 | </FirstTag>
7 | </SecondTag>
8 | Un peu de texte
```

1.3 Structure du document

Le parseur / validateur doit être capable de lire n'importe quel fichier XML-Lite mais doit aussi être en mesure d'attendre une certaine structure de document grâce à l'ajout d'un fichier .dtd appelé schéma. Grâce aux fichiers schéma, le parseur / validateur connaît avec plus de finesse les balises filles autorisées ou non pour chaque balises. C'est une sorte de modèle qui permettra la validation du fichier XML-Lite.

2 Journal de bord

2.1 Séance 1

Lors de la première séance, nous avons tout d'abord effectué le choix de sujet. Le parseur / validateur XML-Lite nous a intéressé étant donné le grand nombre de programmes fonctionnant avec XML pour la persistance et la souplesse de ce format de base de données, nous étions intéressé de découvrir les notions de bases du XML.

Par ailleurs, durant cette séance, nous avons trouvé des informations sur les validateurs de documents et avons pensé à implémenter un automate fini pour modéliser notre validateur. Le design objet "state pattern" semblait particulièrement adapté.

2.2 Séance 2

Lors de la deuxième séance, nous avons modélisé l'automate fini schématiquement, puis, nous l'avons implémenté. Il est utilisé pour valider le document. Nous avons également codé les différents états.

Exemple d'un état du validateur

```
1 public class NewTag implements State {
2     @Override
3     public State transition(char c) {
4         if (c == '/')
5             return new NewClosingTag();
6         else if ((c != '<') && (c != '>')) {
7             XMLLiteParser.getInstance().fillBuffer(c);
8             return new NewTagName();
9         } else
10            return new Error();
11    }
12
13    @Override
14    public boolean isFinal() {
15        return false;
16    }
17 }
```

Puis, nous avons réfléchi à la structure mathématique du parseur, nous sommes vite arrivé à celle d'un arbre. Cette structure à l'avantage d'être facile à designer en objet. Nous avons donc implémenté deux classes :

- XMLLiteNode : Pour représenter une feuille ou un nœud de l'arbre.
- XMLLiteParser : Pour construire l'arbre.

Il a également fallu implémenter un buffer afin de stocker caractère par caractère les informations provenant des états du validateur.

2.3 Séance 3

Après avoir implémenté le parseur en structure d'arbre lors de la séance 2, nous avons pu interfacer une IHM basée sur les noeuds et feuilles de l'arbre nous permettant de faire une représentation claire et précise du fonctionnement du parseur / validateur qui nous servira principalement lors de la présentation de projet.

L'implémentation de la classe JTree nous permet alors de représenter visuellement la structure du fichier XML-Lite analysé formaté en structure d'arbre.

2.4 Séance 4

Lors de la séance 4, nous avons du faire face à une erreur n'arrivant uniquement lors de la lecture de gros fichiers.

La bite.

3 Choix du modèle mathématique

3.1 Le modèle mathématique

Pour nous permettre de parcourir rapidement un fichier XML-Lite, nous avons opté pour le développement d'un automate fini.


Tout d'abord puisque grâce à la simplicité et la rigidité du langage XML-Lite, il y a très peu d'états différents lors de la lecture d'un fichier. De plus, les transitions entre états se font uniquement grâce à la différenciation des caractères '<', '>', '/' et le reste.

Cette façon de parcourir un fichier XML-Lite caractère par caractère s'est avérée très rapide (exécution en 13ms pour un fichier XML-Lite de près de 700Mo).

Enfin, ce modèle mathématique avec une implémentation et un débogage relativement simple permet également une amélioration facile du programme grâce à la différenciation de tous les états dans différentes classes.

3.2 Représentation de l'automate fini

3.2.1 Schéma



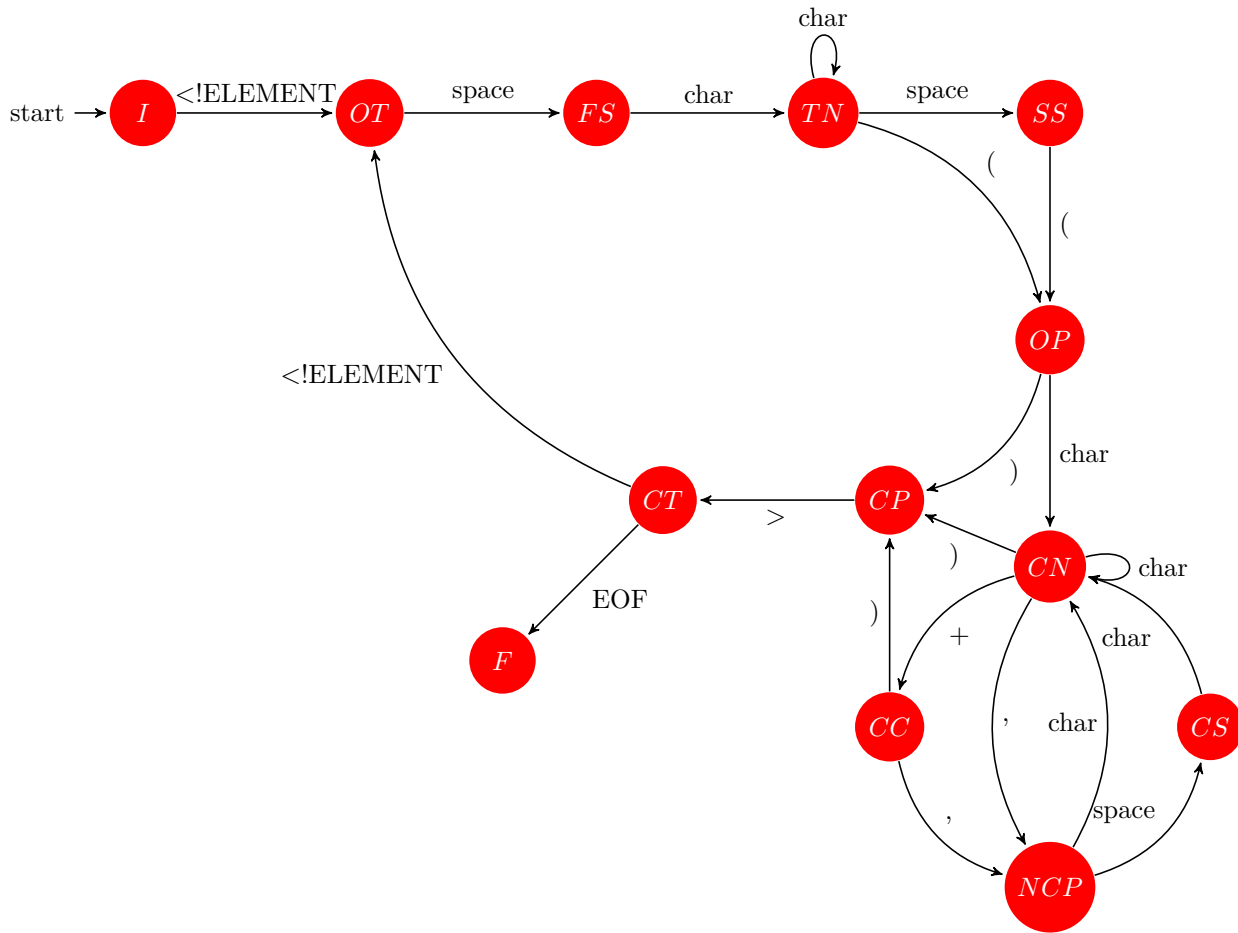
3.2.2 Description des états

- I** Initial
- FTO** First Tag Opening
- NTN** New Tag Name
- ETN** End Tag Name
- TC** Text Content
- NT** New Tag
- NCT** New Closing Tag
- CTN** Closing Tag Name
- ECT** End Closing Tag
- F** Final

3.3 Automate de validation du fichier DTD

Afin d'utiliser un fichier DTD, nous devons vérifier ce fichier DTD. Nous avons ainsi implémenter un automate fini pour vérifier la structure du schéma.

3.3.1 Schéma



3.3.2 Description des états

- I** Initial
- OT** Opening Tag
- FS** First Space
- TN** Tag Name
- SS** Second Space
- OP** Opening Parenthesis
- CN** Child Name
- NCP** Next Child Point
- CS** Child Space
- CP** Closing Parenthesis
- CT** Closing Tag
- F** Final

4 Prolongements possibles

4.1 Permettre le débuggage du fichier XML.

4.2 Permettre au validateur de s'accorder à un schéma prédéfini.

4.3 Modifier le validateur afin qu'il prenne en compte un schéma.

4.4 Ajouter un interpréteur suivant le schéma d'un générateur de QCM.

5 Conclusion

Ce projet aura été d'une grande expérience pour notre groupe. La création d'un outil permettant de parser et valider des documents XML-Lite tout en s'accordant sur un schéma prédéfini ou non nous a permis tout comme nous l'espérons au commencement de ce projet de découvrir les principes de base du XML mais également l'implémentation et la gestion d'un automate fini. En effet,

6 Comment ajouter du code ?

6.1 Comme ça

```
1 package XMLLiteParser;
2
3 import XMLLiteParser.Core.Node;
4 import XMLLiteParser.Core.Parser;
5 import XMLLiteParser.Core.TransitionSystem;
6 import XMLLiteParser.Gui.TreeView;
7 import XMLLiteParser.SchemaTools.SchemaInterpreter;
8
9 import javax.swing.tree.DefaultTreeModel;
10 import java.io.IOException;
11 import java.util.Date;
12 import java.util.regex.Matcher;
13 import java.util.regex.Pattern;
14
15 /**
16  * Created by MrMan on 12/09/2016.
17  */
18 public class main {
19     public static void main(String[] args) {
20         //TODO remove all todos before the end
21         //TODO if we have time : verify class structure
22         long startTime = System.currentTimeMillis();
23
24         TransitionSystem ts = new TransitionSystem();
25         Node rootNode = null;
26
27         try {
28             ts.parseFile("XMLDocs\\Ok.xml");
29             rootNode = Parser.getInstance().getRootNode();
30
31             SchemaInterpreter schemaInterpreter = SchemaInterpreter.getInstance();
32             schemaInterpreter.validateTree(rootNode, "XMLDocs\\QCM.dtd");
33
34         } catch (IOException e) {
35             e.printStackTrace();
36         }
37
38         System.out.println("Document validated in " + (new Date().getTime() - startTime) + "ms");
39
40
41         DefaultTreeModel tm = new DefaultTreeModel(rootNode);
42         TreeView tv = new TreeView(tm);
43
44         tv.setVisible(true);
45     }
46 }
```

6.2 Ou comme ça

yolo

```
1 | class HelloWorldApp {
2 |     public static void main(String[] args) {
3 |         System.out.println("Hello World!"); // Display the string.
4 |         for (int i = 0; i < 100; ++i) {
5 |             System.out.println(i);
6 |         }
7 |     }
8 | }
```